Informe académico de limpieza y preparación de datos
SECOP II – ODS 16.6

Lineamientos metodológicos para la depuración, estandarización y preparación de una base de contratación pública orientada a analítica y Machine Learning

Proyecto	Evaluación de transparencia institucional en procesos SECOP II con enfoque ODS 16.6
Base principal	secop_procesos.parquet y artefactos analíticos derivados del EDA
Propósito	Definir una estrategia defendible de limpieza y preparación de datos para modelado y auditoría analítica

Documento elaborado a partir del informe general del proyecto, las figuras diagnósticas suministradas y la propuesta técnica de limpieza y preparación para ML.

Resumen ejecutivo

Síntesis de hallazgos clave

• La base conserva una estructura suficientemente rica para modelado, pero la dimensión temporal es la más frágil: los nulos se concentran en fechas de recepción, apertura y adjudicación.
• Los boxplots de precio_base y duracion muestran colas derechas extremas; por ello no conviene eliminar observaciones con reglas IQR de forma automática, sino separar errores materiales de valores altos plausibles.
• Existen duplicados exactos y duplicados lógicos por id_del_proceso, por lo que la limpieza debe consolidar registros por proceso antes de entrenar cualquier modelo.
• Las variables posadjudicación y de estado avanzado del trámite deben excluirse del set predictivo para evitar leakage y alinear el análisis con una señal temprana de riesgo de baja transparencia.

1. Contexto académico y objetivo del informe

Este informe formula una estrategia académica de limpieza y preparación de la base SECOP II para un proyecto de Big Data y Machine Learning orientado al ODS 16.6. El propósito no es solo describir problemas de calidad del dato, sino traducirlos en decisiones metodológicas defendibles para la construcción de una base modelable, reproducible y útil para auditoría institucional.

El informe general del proyecto establece que la meta sustantiva no es predecir adjudicación, sino aproximar riesgo de baja transparencia institucional. Bajo ese criterio, la limpieza debe preservar señales sobre completitud, trazabilidad, coherencia temporal y competencia, y al mismo tiempo eliminar variables que revelan el resultado final del procedimiento.

2. Fuentes y criterio metodológico

- Base principal: secop_procesos.parquet, con 450.000 filas y 58 columnas.
- Vista analítica de EDA: datos_analisis.parquet, con 450.000 filas y 49 columnas tras retirar campos posadjudicación.
- Documento conceptual del proyecto: informe_general_secop_ods16.pdf, que relaciona la contratación pública con transparencia institucional y ODS 16.6.
- Documento técnico base de limpieza: informe_limpieza_preparacion_ml_secop.md, en el que se consolidan métricas, reglas y recomendaciones.

- Figuras diagnósticas suministradas: variables temporales vs estado del proceso, boxplot de duración y boxplot de precio base.

En coherencia con las sesiones del curso, el análisis se ubica en la fase de Data Understanding y Data Preparation de CRISP-DM, y se articula con una arquitectura lakehouse Bronze–Silver–Gold y un pipeline orquestado para garantizar trazabilidad y repetibilidad.

3. Diagnóstico de calidad de datos

3.1. Nulos y trazabilidad temporal

La evidencia disponible indica que los nulos no afectan por igual a toda la base: se concentran en las variables temporales. Este patrón es metodológicamente importante porque sugiere ausencia estructural asociada al tipo o avance del proceso y no pérdida aleatoria de información.

Variable	% de nulos	Implicación para limpieza
fecha_de_publicacion_fase	99,9998%	Eliminar: prácticamente vacía y sin utilidad modelable.
fecha_de_publicacion	98,6180%	No usar como fecha ancla.
fecha_de_publicacion_fase_2	96,7240%	Eliminar por alta ausencia.
fecha_adjudicacion	84,9298%	Conservar solo para auditoría, no como predictor temprano.
fecha_de_apertura_de_respuesta	79,3738%	Mantener con bandera de presencia.
fecha_de_apertura_efectiva	76,8362%	Mantener con control de anomalías temporales.
fecha_de_recepcion_de	74,5142%	Mantener sin imputación directa.

La conclusión operativa es clara: las fechas faltantes no deben imputarse de forma mecánica. En una base cuyo objetivo es medir transparencia, inventar fechas degradaría precisamente la señal que se busca analizar.

3.2. Valores atípicos y distribuciones extremas

Las variables numéricas centrales presentan distribuciones altamente asimétricas. Los resúmenes del EDA reportan, entre otros, un máximo de 13.212.285.859.000 en precio_base

y un máximo de 50.000.000 en duracion. Tales colas no implican por sí solas error: en contratación pública es esperable la coexistencia de procesos pequeños y procesos de cuantía excepcional.

Variable	Evidencia clave	Decisión metodológica
precio_base	5 negativos, muchos ceros y cola superior extrema	Convertir negativos a NA, conservar ceros, aplicar log1p y winsorización selectiva.
duracion	Valores implausibles y mezcla de unidades	Normalizar a días antes de recortar extremos.
respuestas_al_procedimiento	Q1=Q3=0 y fuerte cero-inflación	No eliminar con IQR; usar log1p o bandera binaria.
proveedores_unicos_con	Alta correlación con respuestas_al_procedimiento	Evitar redundancia y crear agregados de competencia.

3.3. Inconsistencias y duplicados

El EDA detecta anomalías temporales en 18.468 registros, todas asociadas a la regla fecha_de_apertura_efectiva < fecha_de_recepcion_de. También confirma 18.910 duplicados exactos y 23.648 filas repetidas por id_del_proceso. En términos analíticos, esto obliga a distinguir duplicación física de duplicación lógica, y a adoptar id_del_proceso como clave primaria operativa del dataset limpio.

4. Interpretación de las figuras diagnósticas

Las tres figuras suministradas son especialmente útiles porque permiten traducir la estadística descriptiva a decisiones concretas de limpieza. En un trabajo académico, su valor no es ornamental: muestran por qué ciertas reglas automáticas serían metodológicamente equivocadas.

4.1. Variables temporales vs. estado del proceso

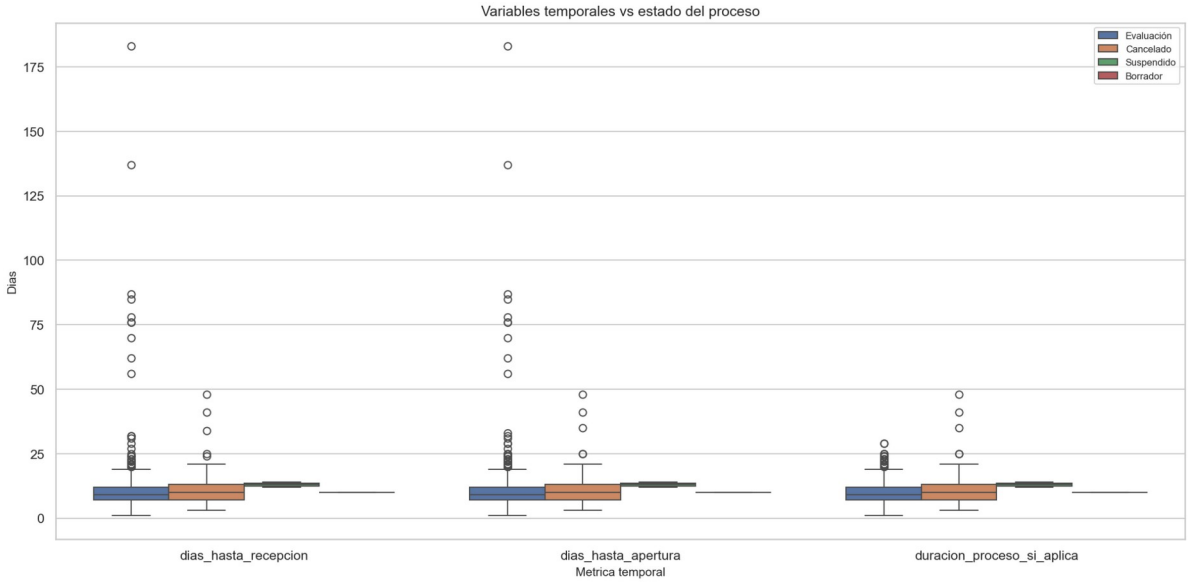

Figura 1. Distribución de métricas temporales por estado del proceso.

La figura evidencia que las ventanas temporales cambian según el estado del proceso y que existen observaciones extremas, sobre todo en Evaluación y Cancelado. Esto refuerza dos ideas: primero, la temporalidad no debe limpiarse con una sola regla global; segundo, varias ausencias y dispersiones probablemente reflejan trayectorias administrativas diferentes y no simple ruido. Por ello, conviene derivar variables de ventana temporal solo cuando los extremos existan y conservar banderas de presencia para el resto.

4.2. Boxplot de duración

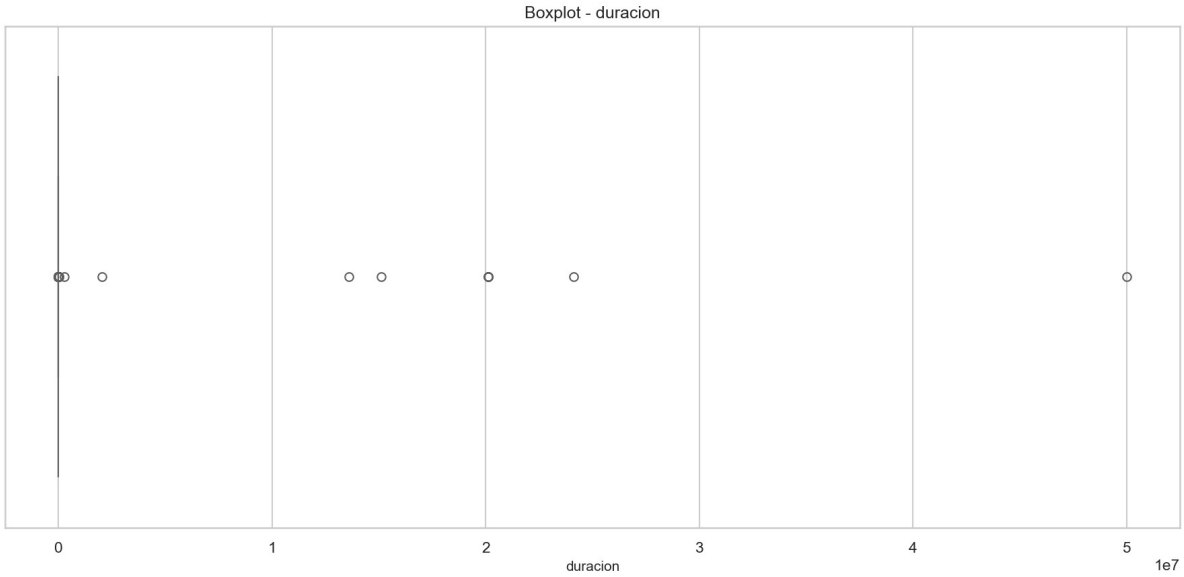

Figura 2. Boxplot de la variable duracion.

El boxplot de duración muestra una concentración muy fuerte cerca del origen y unos pocos valores extraordinariamente altos. Interpretar todos esos puntos como errores sería una simplificación excesiva. La acción correcta es convertir la duración a una escala homogénea en días, marcar valores imposibles y luego estabilizar la cola mediante percentiles altos o transformaciones logarítmicas, no mediante eliminación masiva de filas.

4.3. Boxplot de precio base

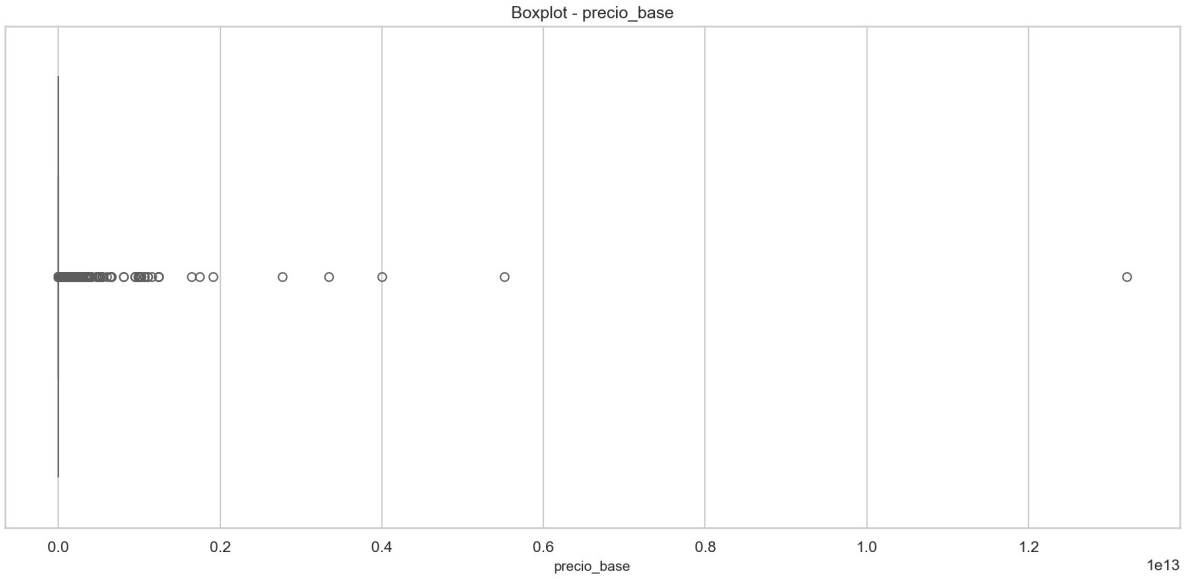

Figura 3. Boxplot de la variable precio_base.

El boxplot de precio_base confirma una asimetría aún más pronunciada. El problema central no es solo la existencia de montos muy altos, sino la convivencia de ceros, valores plausiblemente válidos y un pequeño conjunto de valores materialmente inválidos, como montos negativos. En consecuencia, la limpieza debe ser semántica: negativos a valores perdidos, ceros conservados con bandera propia y winsorización condicionada por modalidad o tipo de contrato, nunca un corte global uniforme.

5. Estrategia de limpieza recomendada

La estrategia propuesta se organiza según el principio de mínima distorsión analítica: corregir lo que es error, preservar lo que es señal y aislar lo que introduce fuga de información.

Decisiones operativas prioritarias

- Eliminar columnas casi vacías: fecha_de_publicacion_fase, fecha_de_publicacion y fecha_de_publicacion_fase_2.
- Conservar las fechas relevantes con indicadores de presencia, sin imputación directa de las

fechas originales.
• Transformar placeholders semánticos como No definido, No Aplica y No Adjudicado en categorías de ausencia diferenciadas.
• Consolidar registros por id_del_proceso tras eliminar duplicados exactos.
• Normalizar duracion usando unidad_de_duracion y limpiar precio_base con reglas de negocio antes de cualquier escalamiento estadístico.

5.1. Nulos

- Eliminar columnas con ausencia extrema y utilidad analítica marginal.
- Crear banderas como tiene_fecha_recepcion, tiene_fecha_apertura_respuesta y tiene_fecha_adjudicacion.
- Usar fecha_de_publicacion_del como fecha ancla por su cobertura completa.
- Evitar imputar fechas originales; si un algoritmo exige completitud, imputar solo variables derivadas numéricas y conservar la bandera de ausencia.

5.2. Outliers

- precio_base < 0 debe tratarse como error material y convertirse a valor perdido.
- Los ceros de precio_base no deben eliminarse de forma automática.
- La variable duracion debe convertirse primero a duracion_dias y solo después evaluarse en términos de percentiles o recorte.
- Las variables de conteo con IQR igual a cero deben tratarse con log1p, winsorización ligera o binarización, no con descarte de observaciones.

5.3. Duplicados e inconsistencias

- Eliminar primero duplicados exactos.
- Adoptar id_del_proceso como clave lógica del proceso.
- Cuando existan varias filas del mismo id_del_proceso, conservar la más completa entre las variables no filtradas por leakage.
- Mantener flags de anomalía temporal y de duplicación para auditoría y trazabilidad del pipeline.

6. Selección de variables para modelado

La depuración no termina con limpiar datos: debe definirse qué columnas sí y cuáles no pueden entrar al modelo. Esta decisión es indispensable para evitar data leakage y para alinear el proyecto con una señal temprana de transparencia.

Grupo	Variables	Tratamiento

Excluir por fuga de información	adjudicado, id_adjudicacion, valor_total_adjudicacion, nombre_del_proveedor, nit_del_proveedor_adjudicado	Eliminar del set predictivo.
Excluir por alta cardinalidad operativa	id_del_proceso, referencia_del_proceso, id_del_portafolio, urlproceso	Conservar solo para trazabilidad externa.
Excluir por redundancia o constancia	ppi, subtipo_de_contrato, proveedores_que_manifestaron	Eliminar por duplicidad exacta o falta de varianza.
Conservar con transformación	precio_base, duracion, respuestas_al_procedimiento, proveedores_unicos_con	Limpiar, transformar y derivar indicadores interpretables.

Entre las variables derivadas más recomendables se encuentran: duracion_dias, precio_base_log, missing_temporal_count, anomalia_temporal, competencia_reportada, intensidad_competencia_log, ratio_proveedores_vs_invitados y medidas de completitud crítica del registro.

7. Pipeline recomendado para una versión reproducible

Desde la perspectiva del curso, la solución más sólida es estructurar el proceso en tres capas. La capa Bronze almacena la extracción cruda; la capa Silver ejecuta limpieza, estandarización, reglas de negocio y deduplicación; la capa Gold publica tablas listas para análisis, indicadores y entrenamiento de modelos. Esta organización coincide con la lógica lakehouse vista en clase y permite separar el dato original del dato preparado.

La orquestación puede implementarse con Prefect: un flujo de extracción, uno de validación y perfilado, uno de limpieza y conformación, y uno de publicación analítica. Esto facilita reintentos, monitoreo de estados, trazabilidad de errores y control de reinicios sin rehacer innecesariamente todo el pipeline.

8. Conclusiones

La base SECOP II no presenta un problema general de inutilidad, sino un conjunto concreto de riesgos de calidad: trazabilidad temporal incompleta, duplicados lógicos por proceso, placeholders semánticos y variables posresultado que inducen leakage. El tratamiento

adecuado no es una limpieza agresiva e indiscriminada, sino una depuración orientada por reglas de negocio, estadística descriptiva y finalidad analítica.

En consecuencia, la limpieza recomendada fortalece tanto la validez del modelado como la consistencia académica del proyecto: preserva evidencia relevante para estudiar transparencia institucional, evita que el algoritmo aprenda el desenlace administrativo y deja una base defendible para auditoría, comparación entre entidades y desarrollo posterior de modelos predictivos o semisupervisados.

Referencias del proyecto

- informe_general_secop_ods16.pdf
- informe_limpieza_preparacion_ml_secop.md
- secop_procesos.parquet y artefactos analíticos derivados del EDA
- Session 1–4 del curso Big Data Tools, en especial CRISP-DM, Data Lakehouse, ETL/ELT y visualización estadística.