Informe de análisis descriptivo SECOP II – Procesos de Contratación

Evaluación de viabilidad del proyecto de Big Data y Machine Learning alineado con el ODS 16.6

Basado en los resultados del perfilamiento descriptivo entregado por el usuario

Conclusión ejecutiva: sí es posible continuar con el proyecto, porque el análisis descriptivo ya demuestra que existe volumen, estructura y variables útiles para construir un modelo orientado al riesgo de baja transparencia. Sin embargo, este análisis por sí solo no basta para pasar directamente a modelado: antes se requiere limpieza focalizada, validación de la etiqueta derivada y análisis inferencial/explicativo.

1. Objetivo del informe

Este informe interpreta los resultados del análisis descriptivo generado sobre la base SECOP II y valora si, con la evidencia actual, el proyecto puede avanzar hacia una solución de Big Data y Machine Learning enfocada en transparencia institucional.

2. Contexto del proyecto

El proyecto se enmarca en la Meta 16.6 del ODS 16, orientada a instituciones eficaces, transparentes y que rindan cuentas. En el material base del proyecto se propone una variable objetivo derivada de "riesgo de baja transparencia", construida a partir de completitud, trazabilidad, coherencia temporal y competencia del proceso.

3. Radiografía general del perfilamiento

Indicador	Valor
Filas	429.541
Columnas	100
Uso de memoria (MB)	520.06
Columnas datetime	3
Columnas numéricas	32

Binarias numéricas	23
Booleanas	16
Categóricas	19
Texto	4
Técnicas	4

La base resumida es suficientemente grande para tratarse como un caso real de analítica de datos públicos: tiene 429.541 registros, 100 columnas y una huella de memoria de aproximadamente 520 MB. La mezcla de variables numéricas, categóricas, booleanas, técnicas y de texto indica que existe base para un pipeline de tipo lakehouse y para etapas posteriores de feature engineering.

4. Hallazgos principales del análisis descriptivo

4.1 Fortalezas para el proyecto

- Alta disponibilidad en columnas estructurales críticas: entidad, NIT, orden de entidad, identificadores del proceso, precio base, modalidad de contratación, URL del proceso y nombre del procedimiento presentan completitud cercana a 100%.
- No existen duplicados exactos en todas las columnas ni duplicados por id_del_proceso, lo que es una señal favorable para la trazabilidad primaria.
- Las variables derivadas de transparencia ya permiten una primera aproximación supervisada: el dataset incluye score_completitud, score_trazabilidad, score_temporal, score_competencia y transparency_score.
- La estructura temporal mínima existe: fecha_de_publicacion_del está completa y cubre principalmente 2021-2022; además hay fechas de recepción y apertura para una parte importante, aunque incompleta, de los procesos.

4.2 Riesgos de calidad detectados

- Las variables temporales operativas presentan una ausencia muy alta. fecha_de_recepcion_de tiene 78,06% de nulos y fecha_de_apertura_de_respuesta 83,04%. Esto afecta directamente cualquier medición robusta de oportunidad, secuencia y duración.
- La competencia observable también está incompleta o sesgada por ceros estructurales. ratio_proveedores_vs_invitados tiene 93,43% de nulos; proveedores_invitados tiene mediana 0 y respuestas_al_procedimiento también tiene mediana 0.
- Hay duplicidad lógica relevante en claves de negocio secundarias: referencia_del_proceso repite 12,19% de filas e id_del_portafolio 8,05%. No necesariamente es error, pero exige reglas claras para consolidación analítica.
- Existen outliers severos en variables clave. precio_base alcanza un máximo extremadamente alto frente a su mediana, y duracion_dias presenta un máximo claramente improbable, lo que obliga a revisar errores de captura y escalas.

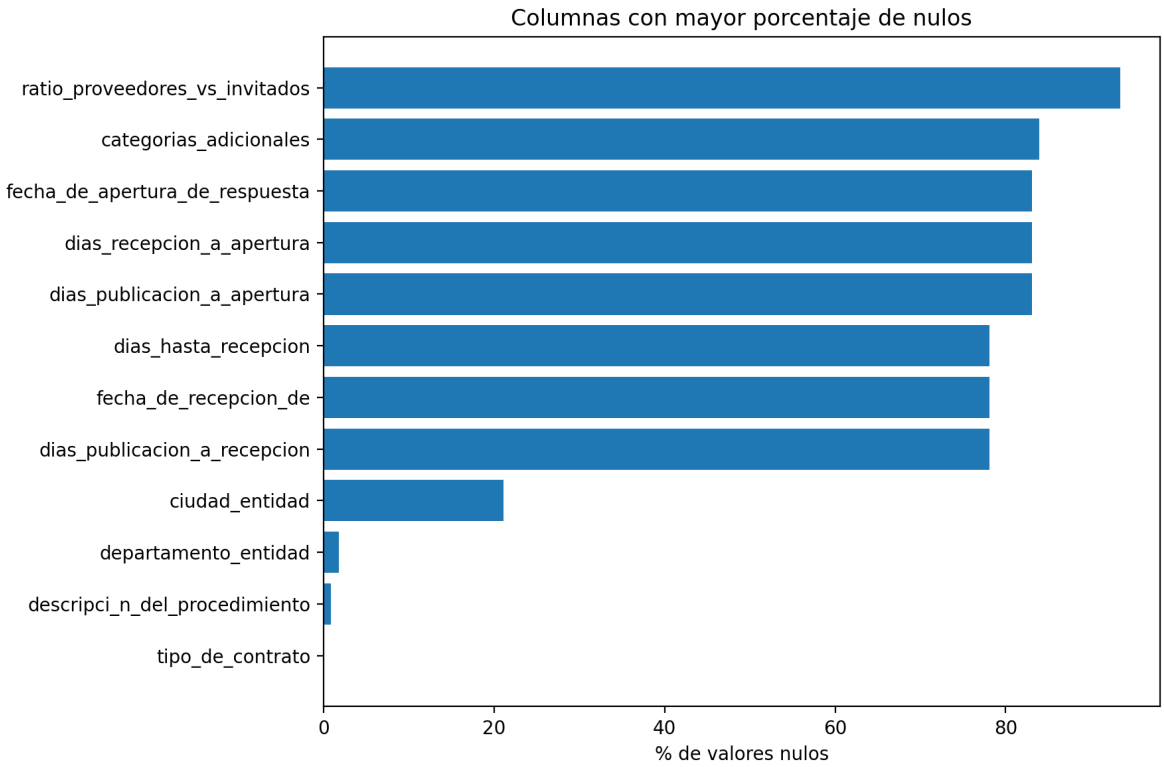

Figura 1. Principales columnas afectadas por nulos.

Columna	% nulos	% completitud
ratio_proveedores_vs_invitados	93.43	6.57
categorias_adicionales	83.94	16.06
fecha_de_apertura_de_respuesta	83.04	16.96
dias_recepcion_a_apertura	83.04	16.96
dias_publicacion_a_apertura	83.04	16.96
dias_hasta_recepcion	78.07	21.93
fecha_de_recepcion_de	78.06	21.94
dias_publicacion_a_recepcion	78.06	21.94
ciudad_entidad	21.11	78.89
departamento_entidad	1.8	98.2

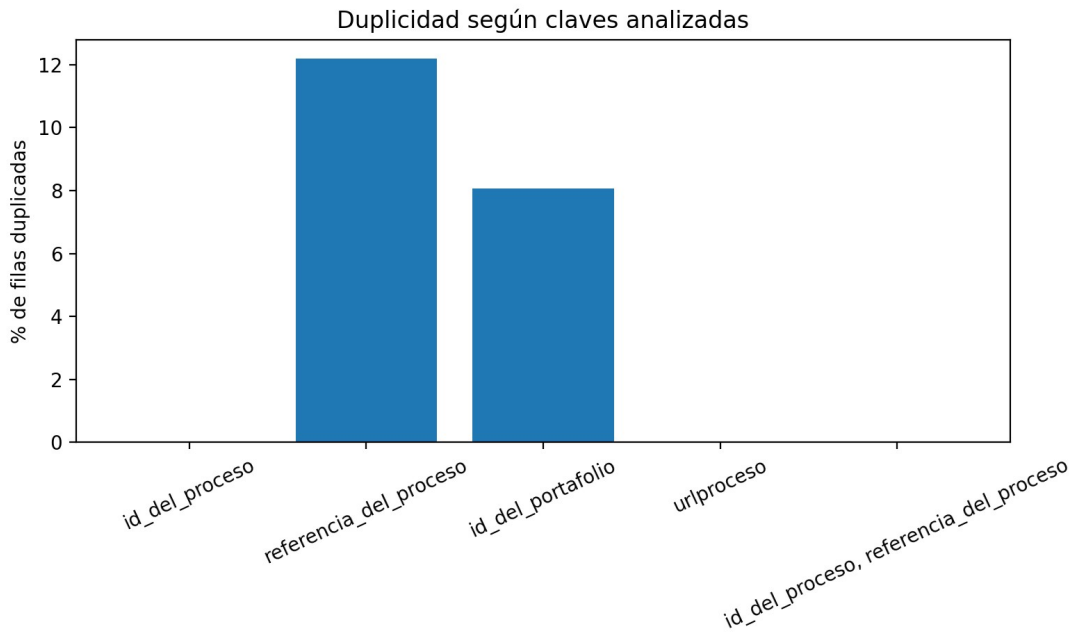

Figura 2. Duplicidad observada según claves evaluadas.

Clave evaluada	Filas duplicadas	Grupos / llaves	% duplicidad
all_columns	0	nan	0.0
id_del_proceso	0	0.0	0.0
referencia_del_proceso	52346	13692.0	12.1865
id_del_portafolio	34599	14324.0	8.0549
urlproceso	50	2.0	0.0116
id_del_proceso, referencia_del_proceso	0	0.0	0.0

4.3 Lectura de los indicadores de transparencia

Los puntajes derivados muestran una situación mixta. Completitud y trazabilidad tienen promedios muy altos (0,955 y 0,997 respectivamente), mientras que el componente temporal es bajo (0,192) y el de competencia también es modesto (0,286). El transparency_score promedio es 0,641. Además, la variable riesgo_baja_transparencia marca 79,32% de casos positivos, lo cual sugiere desbalance de clases y una definición de riesgo muy exigente o muy sensible al faltante temporal.

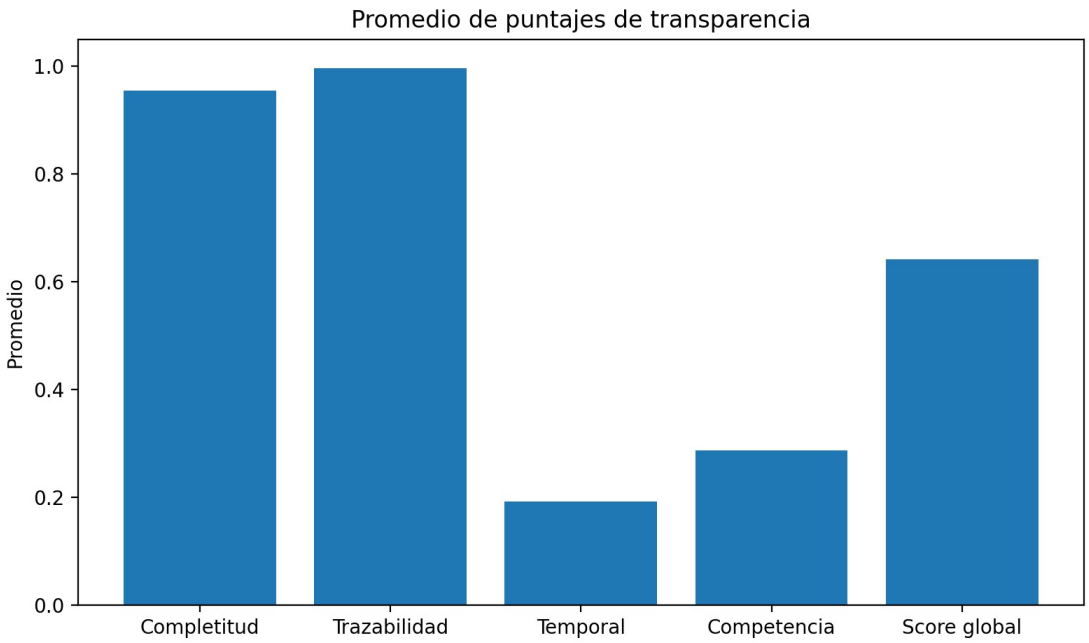

Figura 3. Promedio de los puntajes derivados de transparencia.

Indicador	Valor
Riesgo de baja transparencia (tasa positiva)	79,32%
Categoría dominante de confianza	baja
Participación categoría dominante	61,73%
Nivel de riesgo dominante	medio
Participación nivel dominante	78,62%
Evidence coverage promedio	0,7924
Score completitud promedio	0,9552
Score trazabilidad promedio	0,9966
Score temporal promedio	0,1918
Score competencia promedio	0,2863
Transparency score promedio	0,6409

4.4 Correlaciones útiles y advertencias analíticas

Relación	Correlación	Lectura
proveedores_con_invitacion ↔️ total_interes_oferentes	0,825	Más invitación efectiva tiende a coexistir con mayor interés del mercado.
respuestas_al_procedimiento ↔️	0,699	La respuesta formal del mercado se

total_interes_oferentes		mueve en la misma dirección del interés total.
score_temporal ↔️ visualizaciones_del	0,490	Procesos con mejor cobertura temporal tienden a ser más visibles, aunque la relación es moderada.
precio_base_log ↔️ score_completitud	0,483	Procesos de mayor cuantía parecen estar mejor documentados.
score_competencia ↔️ total_respuestas	0,470	La competencia observada está asociada con mayor actividad de respuesta.

Estas asociaciones son útiles para orientar variables predictoras y reglas de negocio, pero no prueban causalidad. Además, varias correlaciones altas del resumen provienen de variables derivadas entre sí; por tanto, deben tratarse con cuidado para evitar leakage y redundancia.

5. ¿Con este análisis descriptivo se puede hacer el proyecto?

Sí, el análisis descriptivo es suficiente para afirmar que el proyecto es viable y merece continuar. La razón principal es que ya existe evidencia de: (i) volumen de datos, (ii) identificadores confiables, (iii) variables económicas, categóricas y técnicas útiles, (iv) una primera familia de indicadores de transparencia y (v) una estructura suficientemente rica para construir un pipeline ETL/ELT, hacer feature engineering y entrenar modelos tabulares.

No obstante, también es importante precisar el alcance de esta afirmación: el análisis descriptivo no basta para declarar que el modelo ya está listo o que la etiqueta de transparencia es metodológicamente definitiva. Lo que sí demuestra es que el proyecto tiene fundamento técnico y datos suficientes para avanzar a la siguiente fase.

Pregunta	Respuesta	Interpretación
¿Hay suficiente volumen y estructura?	Sí	La base es grande, heterogénea y con variables útiles.
¿Hay señal para definir una variable objetivo?	Sí, de forma preliminar	Ya existen scores y una etiqueta derivada de riesgo.
¿Se puede pasar directo a modelado?	No	Antes se requiere limpieza, validación y partición analítica.
¿El análisis descriptivo aporta valor real al proyecto?	Sí	Permite priorizar columnas, riesgos y reglas de negocio.

6. Qué falta para que el proyecto sea metodológicamente sólido

1. Limpiar y validar variables temporales. La baja cobertura de fechas puede sesgar la noción de transparencia si se usa como castigo automático.

2. Definir reglas para duplicidad lógica en referencia_del_proceso e id_del_portafolio. Debe decidirse si representan re-publicaciones, fases o inconsistencias.
3. Revisar outliers de precio_base y duracion_dias con reglas de negocio, winsorización o filtros por cuantiles, según el caso.
4. Auditar la etiqueta riesgo_baja_transparencia y sus umbrales. Al tener 79,32% de positivos, conviene validar si el riesgo está sobreestimado.
5. Realizar análisis inferencial y explicativo: comparación entre grupos, contraste por modalidad, entidad, territorio y cuantía, además de pruebas de estabilidad.
6. Preparar un conjunto de variables tempranas para evitar data leakage, excluyendo campos que revelen el resultado final del proceso.

7. Ruta recomendada de trabajo

Fase	Propósito
1. Calidad y limpieza	Tipificación, nulos, duplicidad lógica, outliers y catálogos.
2. Validación del labeling	Revisión de fórmulas, umbrales y balance de la etiqueta derivada.
3. Análisis inferencial	Comparar transparencia por entidad, modalidad, territorio y cuantía.
4. Feature engineering	Duraciones consistentes, banderas de completitud, competencia, texto y geografía.
5. Modelado base	Árboles / Random Forest / boosting con validación estratificada.
6. Interpretación	Importancia de variables, error por segmento y utilidad para ODS 16.6.

8. Conclusión final

El análisis descriptivo entregado sí permite seguir con el proyecto. De hecho, cumple una función decisiva: demuestra que la base SECOP II posee tamaño, estructura y señal suficientes para desarrollar un caso serio de Big Data y Machine Learning aplicado a transparencia institucional. La evidencia más fuerte a favor del proyecto está en la robustez de las variables estructurales, la ausencia de duplicados exactos por identificador principal, la disponibilidad de columnas económicas y procedimentales, y la existencia de indicadores derivados de transparencia.

Sin embargo, la misma exploración descriptiva también deja claro que el éxito del proyecto dependerá de cómo se resuelvan tres problemas: la baja cobertura temporal, la duplicidad lógica en llaves secundarias y la validación metodológica de la etiqueta de riesgo. Por tanto, la decisión correcta no es detener el proyecto, sino avanzar con una fase de depuración y validación antes del modelado.

9. Referencias de insumo

- Resultados de perfilamiento descriptivo en archivos CSV suministrados por el usuario: dataset_overview, null_profile, numeric_summary, categorical_summary, duplicates_summary, datetime_summary, correlation_matrix, transparency_summary, column_inventory y dtypes.
- Informe general del proyecto SECOP II – ODS 16.6 suministrado por el usuario.
- Material del curso Big Data Tools sobre fundamentos, formatos de datos, orquestación con Prefect y análisis exploratorio.