Informe de análisis inferencial

Base SECOP II – Evaluación de viabilidad del proyecto Big Data / Machine Learning

Conclusión ejecutiva

Sí, con este análisis inferencial el proyecto es viable, siempre que el objetivo sea predictivo y no causal. La evidencia estadística muestra asociaciones fuertes entre variables de proceso y señales de transparencia, pero también obliga a controlar fuga de información, outliers extremos y la inferencia inflada por el tamaño muestral.

Fuentes analizadas: supuestos estadísticos, pruebas χ^2, intervalos de confianza, comparaciones entre grupos, pruebas post hoc y correlaciones inferenciales generadas sobre ~429 mil registros.

Métrica	Resultado clave
Tamaño analizado	Hasta 429,541 observaciones
Supuestos paramétricos	0 de 25 comparaciones recomendaron pruebas paramétricas
Estructura más influyente	modalidad_de_contratacion sobre transparency_score (ε^2=0.656)
Indicadores binarios	anomalia_temporal=4.21%; competencia_reportada=14.92%
Dirección analítica	Proyecto recomendable para clasificación / scoring de riesgo

Documento generado automáticamente a partir de los resultados inferenciales suministrados por el usuario y del planteamiento del proyecto orientado al ODS 16.6.

1. Qué aporta este análisis inferencial

El análisis inferencial permite pasar del simple perfilamiento descriptivo a una evaluación de evidencia estadística: si existen diferencias sistemáticas entre grupos, si ciertas variables están asociadas entre sí, y si los indicadores de transparencia tienen una señal suficientemente estable para respaldar un proyecto de aprendizaje automático.

En este caso, el valor del análisis no está en demostrar causalidad, sino en confirmar que el comportamiento de los procesos de contratación no es aleatorio y que varias dimensiones del problema presentan estructura estadística utilizable para modelado predictivo.

2. Hallazgos sobre supuestos estadísticos

Las 25 comparaciones revisadas incumplen normalidad por grupos y casi todas también incumplen homocedasticidad. Por tanto, las pruebas no paramétricas utilizadas son coherentes con la naturaleza real de los datos.

Indicador	Resultado
Comparaciones evaluadas	25
Todas las comparaciones con normalidad por grupos	No (25/25 fallan)
Comparaciones con homocedasticidad	3 de 25
Pruebas paramétricas recomendadas	0 de 25
Interpretación	La distribución es altamente asimétrica y con valores extremos; se justifican pruebas robustas y modelos no lineales

Implicación práctica: para el proyecto conviene privilegiar árboles, Random Forest, Gradient Boosting o XGBoost, así como transformaciones logarítmicas, winsorización y métricas robustas. Forzar supuestos gaussianos sería metodológicamente débil.

3. Señales básicas del fenómeno

Los intervalos de confianza muestran que la base no es homogénea ni trivial. Existen eventos de interés suficientemente frecuentes para modelar riesgo, pero no tan dominantes como para volver irrelevante la clasificación.

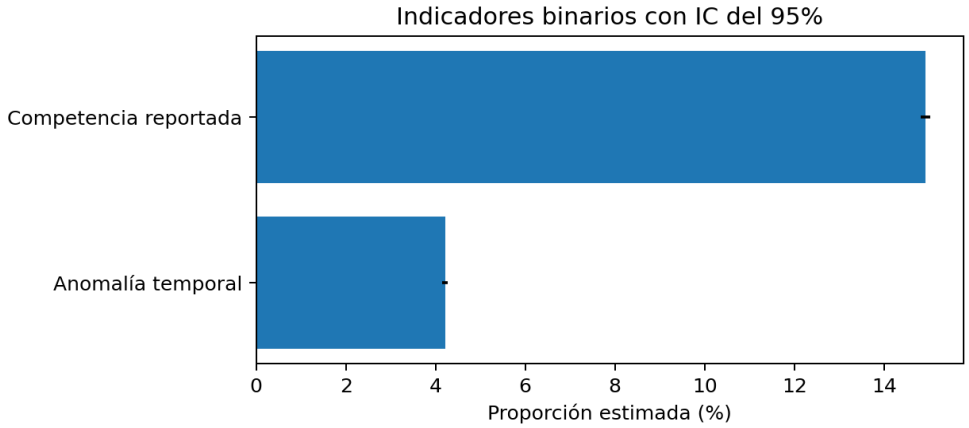

Indicador	Estimación	IC 95%
Anomalía temporal	4.21%	[4.15%, 4.27%]

Indicador	Estimación	IC 95%
Competencia reportada	14.92%	[14.81%, 15.02%]
Transparency score (media)	0.6409	[0.6405, 0.6413]
Score de completitud (media)	0.9552	[0.9549, 0.9554]
Duración en días (media)	575.49	[248.59, 902.40]

4. Diferencias entre grupos: evidencia fuerte y utilizable

Las pruebas Kruskal–Wallis indican que variables estructurales del proceso separan claramente el comportamiento del transparency_score y, en menor medida, la duración. El patrón más fuerte aparece en modalidad_de_contratacion y justificacion_modalidad.

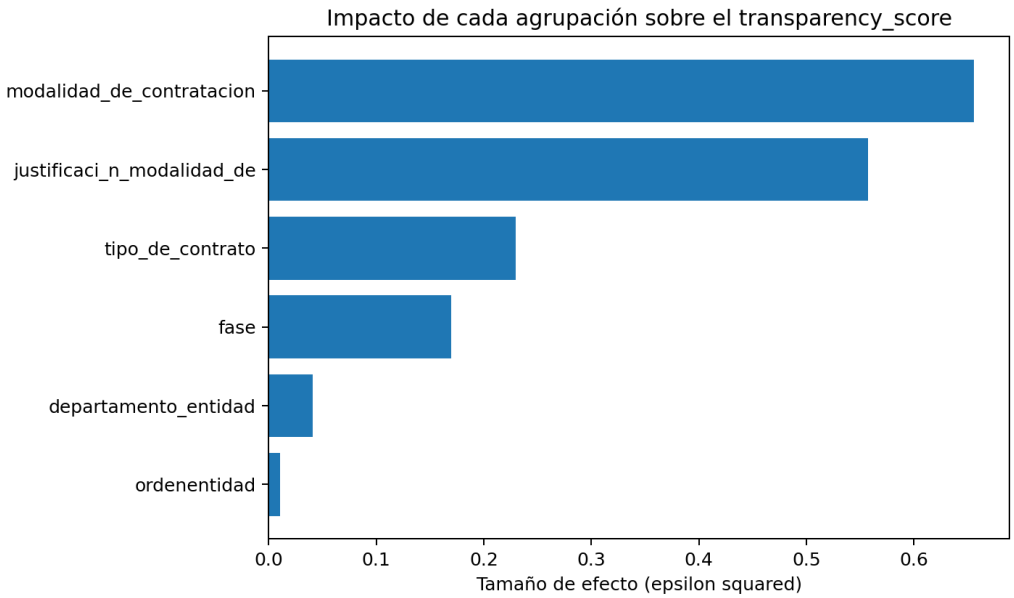

Outcome	Agrupación	Prueba	Tamaño de efecto	Lectura
transparency_score	modalidad_de_contratacion	Kruskal-Wallis	$\varepsilon^2 = 0.656$	Efecto muy grande
transparency_score	justificacion_modalidad	Kruskal-Wallis	$\varepsilon^2 = 0.557$	Efecto muy grande
transparency_score	tipo_de_contrato	Kruskal-Wallis	$\varepsilon^2 = 0.230$	Efecto grande
duracion_dias	tipo_de_contrato	Kruskal-Wallis	$\varepsilon^2 = 0.067$	Efecto pequeño-moderado
duracion_dias	departamento_entidad	Kruskal-Wallis	$\varepsilon^2 = 0.043$	Efecto pequeño

Interpretación: la transparencia no parece depender solo de ruido aleatorio, sino de patrones consistentes ligados al tipo de procedimiento. Eso es favorable para construir una variable objetivo como riesgo de baja transparencia o para modelar un transparency_score.

Además, las pruebas post hoc para ordenentidad muestran diferencias significativas entre Nacional, Territorial y Corporación Autónoma en cinco outcomes (duración, precio, interés, respuestas y transparency_score). Esto sugiere que la jerarquía institucional agrega señal al problema.

Ejemplos interpretables

Dimensión	Grupo con media más alta	Media	Grupo con media más baja	Media
transparency_score por modalidad	Mínima cuantía	0.938	Contratación régimen especial	0.568
transparency_score por modalidad	Régimen especial con ofertas	0.910	Contratación directa	0.580

Dimensión	Grupo con media más alta	Media	Grupo con media más baja	Media
transparency_score por justificación	Presupuesto <10% menor cuantía	0.938	Convenios interadministrativos (valor cero)	0.568

5. Correlaciones: qué variables se mueven juntas

La estructura correlacional confirma que varias variables operativas capturan dimensiones relacionadas entre sí. Las asociaciones más útiles para el proyecto son las que conectan actividad del proceso, interés de oferentes y transparencia.

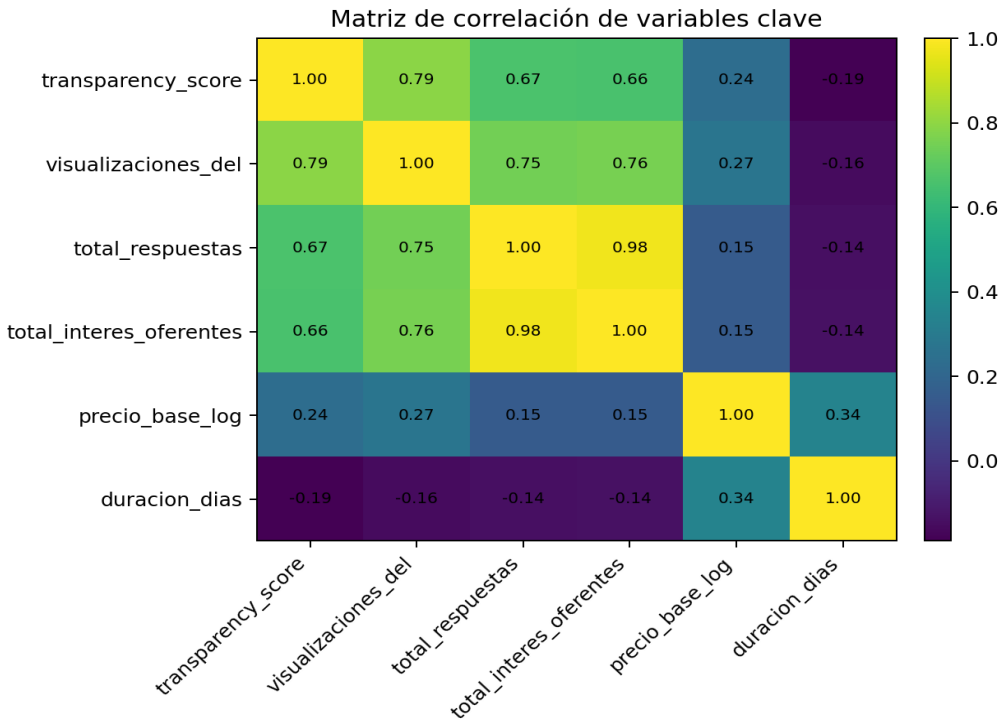

Par de variables	Coeficiente	Lectura
transparency_score – visualizaciones_del	0.792	Asociación alta; procesos más visibles tienden a puntuar mejor
transparency_score – total_respuestas	0.665	Asociación moderada-alta; más interacción, mayor score
transparency_score – total_interes_oferentes	0.657	Interés de mercado ligado a mejor señal de transparencia
duracion_dias – transparency_score	-0.189	Relación negativa débil; procesos más largos tienden a peor score
precio_base_log – duracion_dias	0.342	Montos más altos suelen asociarse con mayor duración

Precaución: algunas correlaciones muy altas reflejan variables casi redundantes o derivadas de la misma construcción. Estas relaciones son útiles para diagnóstico, pero no todas deben entrar juntas al modelo final.

6. ¿Con este análisis sí se puede hacer el proyecto?

Sí. La evidencia inferencial es suficiente para justificar un proyecto de analítica predictiva sobre riesgo de baja transparencia o sobre un score de transparencia. El análisis prueba que hay diferencias significativas entre tipos de proceso, asociaciones robustas con variables de competencia y visibilidad, y proporciones de eventos relevantes que permiten formular un problema de clasificación o scoring.

Pregunta	Respuesta
¿Sirve para un proyecto predictivo?	Sí. Hay señal estadística consistente y suficiente heterogeneidad.
¿Sirve para afirmar causalidad?	No. Las pruebas son observacionales y no aíslan mecanismos causales.
¿La significancia basta por sí sola?	No. Con n≈429 mil casi todo puede ser significativo; hay que priorizar tamaño de efecto y validación externa.
¿Qué objetivo es más sólido?	Clasificar riesgo_baja_transparencia o predecir un transparency_score.
¿Qué familias de modelos encajan mejor?	Árboles, Random Forest, Gradient Boosting, XGBoost, CatBoost; eventualmente regresión regularizada como línea base.

7. Condiciones para que el proyecto sea metodológicamente fuerte

- Definir explícitamente la variable objetivo y documentar cómo se construye. Si el target usa completitud, trazabilidad o competencia, esas mismas piezas no deben entrar al modelo sin control de fuga de información.
- Separar variables derivadas altamente redundantes. No conviene entrenar con pares casi equivalentes.
- Aplicar winsorización o clipping para montos y duraciones extremas, y usar escalas logarítmicas cuando corresponda.
- Validar con división temporal o por entidad, no solo con partición aleatoria. Así se mide mejor la capacidad de generalización.
- Tratar el desbalance de clases si riesgo_baja_transparencia resulta minoritaria; usar ROC-AUC, PR-AUC, F1 y calibration plots.
- Cerrar el ciclo CRISP-DM: entendimiento del negocio, preparación, modelado, evaluación y despliegue.

8. Veredicto final

El análisis inferencial respalda el proyecto. No solo hay significancia estadística; también hay tamaños de efecto grandes en variables estructurales, patrones de asociación consistentes y una arquitectura conceptual compatible con el objetivo del ODS 16.6. La recomendación es continuar con feature engineering, control de leakage y entrenamiento de modelos tabulares robustos. Lo que todavía no se puede afirmar con este análisis es causalidad o explicación normativa del fenómeno, pero sí se puede construir un sistema predictivo útil para priorización, monitoreo o auditoría de procesos.

Anexo breve de lectura: la evidencia más fuerte del estudio no está en la media global, sino en cómo cambian los scores y la duración según modalidad, justificación y orden institucional. Ese comportamiento sugiere que el problema es modelable y que la señal estadística está alineada con el objetivo del proyecto.