

SECOP Transparencia Temprana

Analítica, modelado y operacionalización de riesgo de baja transparencia en procesos

SECOP II

Nicolas Joel Caceres Parra - 0000273195

Sara Juliana López Angarita - 0000281222

Nestor Andres Tabares David - 000287880

Asignatura: Big Data

Institución: Universidad de La Sabana

Programa: Ingeniería Industrial

Profesor: Hugo Franco Triana

Fecha de entrega: 4 de mayo de 2026

Lugar: Chia, Colombia

2. Resumen ejecutivo

Este proyecto desarrolla un flujo de Big Data para analizar procesos de contratación pública publicados en SECOP II y estimar, en etapas tempranas, el riesgo de baja transparencia. El enfoque se alinea con el ODS 16.6, que promueve instituciones eficaces, responsables y transparentes (Naciones Unidas, s. f.). La solución no busca predecir adjudicaciones ni reemplazar auditorías, sino convertir datos abiertos de contratación en señales medibles de completitud, trazabilidad, coherencia temporal y competencia.

La base cruda contiene 450.000 procesos y 58 columnas. Después de construir una vista analítica sin campos posadjudicación, limpiar duplicados y enriquecer variables, el conjunto final de feature engineering queda en 429.541 registros y 106 columnas. El pipeline produce indicadores de calidad institucional, etiquetas de riesgo y artefactos reproducibles en las carpetas Data, Reports, Models y Docs.

El mejor modelo reportado en el experimento temprano es LogisticRegression_early, con F1 de prueba de 0,9941. No obstante, las métricas superiores a 0,995 activan una advertencia metodológica de posible leakage por lo cual se decidió utilizar RandomForest_early. La operacionalización actual usa FastAPI, Docker y un pipeline RandomForest_early con umbral 0,645 para servir predicciones a través de una API y un formulario web.

3. Abstract

This project implements a Big Data pipeline to analyze public procurement procedures from Colombia's SECOP II platform and estimate early risk of low transparency. The proposal is aligned with SDG target 16.6, which focuses on effective, accountable and transparent

institutions. The objective is not to predict awards, but to transform open procurement data into measurable signals related to completeness, traceability, temporal consistency and competition.

The raw dataset contains 450,000 records and 58 variables. After excluding post-award fields, cleaning records and performing feature engineering, the final analytical dataset contains 429,541 records and 106 variables. The operational component deploys the model through FastAPI and Docker as a reproducible academic prototype for risk screening.

4. Introducción

a) Formulación del Problema y Necesidades de Información Asociadas

La contratación pública concentra decisiones de gasto con impacto social, fiscal e institucional. En Colombia, SECOP II permite consultar procesos de contratación en línea y acceder a datos abiertos del sistema de compra pública (Colombia Compra Eficiente, 2024). Sin embargo, el volumen, la heterogeneidad y la presencia de campos incompletos dificultan que un analista identifique de forma temprana procesos que ameritan revisión por baja transparencia.

El problema analítico se formula así: ¿es posible construir, a partir de datos abiertos de SECOP II y antes de observar resultados posadjudicación, un modelo reproducible que estime el riesgo de baja transparencia de un proceso contractual? La Tabla 1 sintetiza las necesidades de información que guían el proyecto y muestra cómo cada necesidad se traduce en variables o indicadores del pipeline.

Tabla 1. Necesidades de información y respuesta analítica del proyecto.

Necesidad de información	Respuesta analítica	Ejemplos de variables
Identificar procesos y entidades	Caracterización del proceso y la entidad responsable.	entidad, nit_entidad, departamento_entidad, ciudad_entidad, ordenentidad

Medir completitud	Revisión de campos requeridos y descripción útil.	missing_required_fields_count, flag_tiene_descripcion_util, score_completitud
Medir trazabilidad	Validación de identificadores, URL pública y disponibilidad de hitos.	flag_id_proceso_valido, flag_tiene_url_publica, score_trazabilidad
Evaluar coherencia temporal	Cálculo de ventanas y anomalías entre publicación, recepción y apertura.	dias_publicacion_a_recepcion, anomalia_temporal, score_temporal
Aproximar competencia	Conteo de respuestas, oferentes e intensidad de participación.	total_respuestas, total_interes_oferentes, score_competencia
Clasificar riesgo	Construcción de etiquetas y entrenamiento de modelos supervisados.	transparency_score, nivel_riesgo_transparencia, riesgo_baja_transparencia

b) Marco conceptual

Transparencia institucional se entiende como la disponibilidad de información suficiente, verificable y oportuna sobre la actuación pública. En contratación, esta noción se conecta con la publicación de datos y documentos durante el ciclo contractual, la trazabilidad de los expedientes y la posibilidad de escrutinio ciudadano. El estándar OCDS propone publicar datos estructurados y documentos de las etapas de contratación para aumentar la transparencia y permitir análisis más profundos (Open Contracting Partnership, s. f.).

Riesgo de baja transparencia no equivale a corrupción probada. En este trabajo se usa como una etiqueta analítica derivada de señales observables: registros incompletos, baja trazabilidad, incoherencias temporales y participación limitada.

Aprendizaje supervisado se refiere al entrenamiento de modelos que aprenden una relación entre variables predictoras y una etiqueta objetivo. En el proyecto, esta etiqueta es el riesgo de baja transparencia. Para mantener reproducibilidad y evitar contaminación entre

entrenamiento y prueba, el preprocesamiento se encapsula en pipelines de scikit-learn, biblioteca ampliamente usada para aprendizaje automático en Python (Pedregosa et al., 2011).

c) Antecedentes

Los antecedentes se agrupan en tres líneas. Primero, las políticas de datos abiertos de contratación en Colombia ofrecen información estructurada de SECOP y promueven decisiones informadas, control ciudadano y rendición de cuentas (Colombia Compra Eficiente, 2025).

Segundo, las recomendaciones internacionales de contratación pública resaltan la transparencia como condición para competencia, integridad y rendición de cuentas (OECD, 2019). Tercero, los estudios de red flags muestran que los registros administrativos de contratación pueden usarse para construir índices objetivos de riesgo y modelos de priorización, siempre que se controlen sesgos y calidad de etiquetas.

Decarolis y Giorgiantonio (2022) aplican herramientas estandarizadas de machine learning para evaluar indicadores de riesgo en licitaciones italianas. Estos trabajos justifican el enfoque del proyecto: usar datos abiertos para construir señales preventivas, no para declarar irregularidades de forma automática.

d) Objetivo del proyecto

Objetivo general: construir y operacionalizar un flujo reproducible de datos y analítica que permita estimar, con información temprana de procesos SECOP II, el riesgo de baja transparencia asociado a completitud, trazabilidad, coherencia temporal y competencia.

Objetivos específicos:

- Descargar y conservar procesos SECOP II desde datos.gov.co en formato Parquet.

- Crear una vista analítica sin columnas posadjudicación que puedan contaminar el análisis temprano.
- Limpiar, normalizar y enriquecer la base con variables de calidad institucional.
- Entrenar y comparar modelos de machine learning para clasificar riesgo de baja transparencia.
- Servir el mejor flujo disponible mediante una API FastAPI y un formulario web de consulta.

5. Datos empleados

La fuente principal es el conjunto SECOP II - Procesos de Contratación, que registra procesos de compra hechos en la plataforma SECOP II, adjudicados o no, y se publica como datos abiertos por Colombia Compra Eficiente. En la documentación oficial se reporta como un conjunto de gastos gubernamentales, de vista pública y actualización diaria (Colombia Compra Eficiente, 2024). La Tabla 2 presenta la evolución de los datos usados en el proyecto.

Tabla 2. Fuentes internas y evolución de los conjuntos de datos.

Archivo	Filas	Columnas	Uso en el proyecto
Data/Raw/secop_procesos.parquet	450.000	58	Base cruda descargada desde SECOP II/datos.gov.co.
Data/Raw/datos_analisis.parquet	450.000	49	Vista analítica sin campos posadjudicación.
Data/Processed/Limpieza/datos_analisis_limpio.parquet	429.541	58	Base depurada para análisis descriptivo e inferencial.
Data/Processed/Limpieza/datos_feature_engineering.parquet	429.541	106	Base enriquecida con scores, flags y targets.
Data/Processed/Model/train_early.parquet	257.724	16	Partición de entrenamiento del experimento temprano.
Data/Processed/Model/validation_early.parquet	85.908	16	Partición de validación para umbrales y selección.
Data/Processed/Model/test_early.parquet	85.909	16	Partición de prueba final.

Las variables independientes corresponden a información disponible antes o durante fases iniciales del proceso: entidad, ubicación, modalidad, tipo contractual, objeto, categoría y precio base. La variable dependiente principal es riesgo_baja_transparencia, derivada de los indicadores de transparencia. La Tabla 3 resume la estructura de variables modeladas y evita confundir variables de entrada con etiquetas o variables auxiliares de auditoría.

Tabla 3. Variables independientes, dependientes y auxiliares.

Tipo	Variables o familias	Descripción
Independientes tempranas	entidad, nit_entidad, departamento_entidad, ciudad_entidad, ordenentidad	Identificación institucional y geográfica.
Independientes tempranas	nombre_del_procedimiento, descripci_n_del_procedimiento, fase	Texto y estado inicial del proceso.
Independientes tempranas	precio_base, precio_base_log	Valor estimado del proceso y transformación logarítmica.
Independientes tempranas	modalidad_de_contratacion, justificaci_n_modalidad_de, codigo_principal_de_categoria, tipo_de_contrato, categorias_adicionales	Características contractuales y clasificación del bien o servicio.
Dependiente legacy	riesgo_baja_transparencia	Etiqueta binaria: 340.715 positivos, equivalentes al 79,32%.
Dependiente alternativa	riesgo_baja_transparencia_v2	Etiqueta estricta: 1.484 positivos, equivalentes al 0,35%.
Auxiliares de interpretación	score_completitud, score_trazabilidad, score_temporal, score_competencia, transparency_score	Indicadores usados para análisis y construcción de etiquetas.

6. Materiales y Métodos

La solución se implementa en Python y organiza artefactos por capas: Code para scripts y API, Data para datos crudos y procesados, Reports para métricas y validaciones, Models para

pipelines entrenados y Docs para informes. La Tabla 4 resume los materiales usados en el proyecto.

Tabla 4. Materiales, herramientas y artefactos principales.

Categoría	Material/herramienta	Función
Lenguaje	Python 3.11/3.12	Procesamiento de datos, análisis, modelado y generación de reportes.
Datos	Parquet, CSV, JSON	Almacenamiento eficiente de datos crudos, procesados y reportes.
Librerías	pandas, pyarrow, scipy, statsmodels, scikit-learn, joblib	Limpieza, inferencia, modelado y serialización.
Modelos opcionales	XGBoost, LightGBM, CatBoost	Comparación de algoritmos de boosting y árboles.
Operacionalización	FastAPI, Uvicorn, Docker, PostgreSQL	API de predicción, contenedores y persistencia.
Control de salidas	Reports/Model, Reports/FeatureEngineering	Métricas, umbrales, matrices, curvas e importancias.

La Tabla 5 muestra el flujo metodológico completo. Cada etapa produce salidas verificables y se conecta con la etapa siguiente, lo que permite reproducir el proyecto durante la evaluación.

Tabla 5. Flujo metodológico reproducible.

Etapas	Procedimiento	Salida principal
Descarga	Consulta a Socrata/datos.gov.co y persistencia local.	Data/Raw/secop_procesos.parquet
Vista analítica	Eliminación de campos posadjudicación y reducción del riesgo de leakage temprano.	Data/Raw/datos_analisis.parquet
Limpieza	Normalización de texto, fechas, numéricos, tokens semánticos y duplicados.	Data/Processed/Limpieza/datos_analisis_limpio.parquet
Feature	Creación de flags,	Data/Processed/Limpieza/datos_feature_engineering.parquet

engineering	ventanas temporales, scores y targets.	
EDA e inferencia	Resumen de calidad, distribuciones, pruebas de grupos y asociaciones.	Data/Processed/Descriptivo e inferencial
Modelado	Pipelines con imputación, codificación, escalamiento, entrenamiento y validación.	Models/trained y Reports/Model
API	Carga del pipeline, cálculo de precio_base_log, predicción y respuesta JSON.	Code/Operationalization/secop_fastapi

En modelado se probaron regresión logística, árbol de decisión, Random Forest, Gradient Boosting, XGBoost, LightGBM y CatBoost. El modo early limita las variables a información temprana y excluye identificadores granulares, variables de resultado, variables postevento y columnas derivadas directamente del target. Esta política es coherente con la recomendación de evitar que el modelo aprenda reglas tautológicas en lugar de patrones generalizables.

7. Resultados

7.1 Calidad y estructura de datos

El procesamiento redujo la base de 450.000 a 429.541 registros tras depuración. La base enriquecida conserva 106 columnas y permite analizar dimensiones de transparencia. La Tabla 6 resume las señales de calidad más relevantes, todas citadas aquí antes de su presentación.

Tabla 6. Señales principales de calidad y transparencia.

Dimensión	Resultado observado	Interpretación
Duplicados	0 duplicados exactos y 0 duplicados por	La limpieza redujo ruido físico y

	id_del_proceso en la base descriptiva final.	lógico clave.
Nulos temporales	fecha_de_apertura_de_respuesta: 83,04%; fecha_de_recepcion_de: 78,06%.	La temporalidad es la dimensión de trazabilidad más frágil.
Precio base	Media 403,5 millones; mediana 14,5 millones; p95 496,0 millones.	Variable fuertemente asimétrica; conviene usar log1p y controles robustos.
Complejidad	score_complejidad medio 0,9552.	Los campos estructurales están relativamente completos.
Trazabilidad	score_trazabilidad medio 0,9966.	Los identificadores y URL suelen estar disponibles.
Temporalidad	score_temporal medio 0,1918.	La ausencia de hitos temporales limita análisis cronológicos.
Competencia	score_competencia medio 0,2863.	La participación observada es baja o incompleta en muchos registros.
Riesgo	nivel_riesgo_transparencia más común: medio, 78,62%.	La mayoría de procesos queda en una zona intermedia de alerta.

7.2 Resultados inferenciales

El análisis inferencial revisó 100 variables candidatas, 25 comparaciones de grupos, 66 asociaciones categóricas, 103 asociaciones numéricas, 20 intervalos de confianza para medias y 40 para proporciones. La Tabla 7 presenta señales destacadas y se interpreta con énfasis en tamaños de efecto, no solo en p-valores.

Tabla 7. Señales inferenciales destacadas.

Relación	Método	Resultado	Lectura
duracion_dias vs tipo_de_contrato	Kruskal-Wallis	p=0; epsilon ² =0,0671	Diferencias pequeñas a moderadas por tipo contractual.
duracion_dias vs modalidad_de_contratacion	Kruskal-Wallis	p=0; epsilon ² =0,0529	La modalidad se asocia con duraciones distintas.
confianza_label vs competencia_reportada	Chi-cuadrado	p=0; V de Cramer=0,6567	Asociación fuerte entre confianza y competencia.
competencia_reportada vs	Chi-cuadrado	p=0; V de	Relación moderada

anomalia_temporal		Cramer=0,3220	entre competencia y anomalías temporales.
conteo_de_respuestas_a_ofertas vs precio_base	Pearson/Spearman	r=0,0021; rho=0,0698	Relación práctica muy baja aunque detectable por tamaño muestral.

7.3 Resultados de modelado

La Tabla 8 presenta la comparación de modelos en modo early. El mejor modelo seleccionado por F1 fue LogisticRegression_early, aunque todos los modelos presentan métricas muy altas y advertencias automáticas por posible leakage.

Tabla 8. Resultados de validación del experimento early.

Modelo	Umbral	Accuracy	Precision	Recall	F1
LogisticRegression_early	0,270	0,9912	0,9955	0,9934	0,9944
XGBoost_early	0,285	0,9890	0,9928	0,9933	0,9931
LightGBM_early	0,390	0,9890	0,9954	0,9908	0,9931
RandomForest_early	0,645	0,9885	0,9926	0,9929	0,9928
CatBoost_early	0,325	0,9882	0,9925	0,9926	0,9926

En prueba, LogisticRegression_early obtuvo Accuracy 0,9906, Precision 0,9951, Recall 0,9931, F1 0,9941, ROC AUC 0,9996 y PR AUC 0,9999. La validación cruzada estratificada reportó F1 medio de 0,9936 con desviación estándar de 0,0002. Aunque estos resultados son competitivos, su magnitud exige validar la etiqueta, los umbrales y la separación temporal antes de sostener conclusiones institucionales.

7.4 Operacionalización

La aplicación operativa se implementa con FastAPI. El servicio expone GET / para el formulario web, GET /api/health para verificar el estado y POST /api/predict para recibir variables de un proceso y devolver probabilidad, etiqueta de riesgo y factores clave. El backend calcula precio_base_log y carga Models/trained/all_models/RandomForest_early_pipeline.joblib con umbral 0,645.

Existe una diferencia documentada entre el mejor modelo reportado por el experimento early (LogisticRegression_early) y el modelo servido por la API (RandomForest_early). Esta diferencia se hizo dado que aunque la mayoría de los modelos están sobre ajustados en el que tiene menor sobre ajuste es el RandomForest_early.

8. Discusión y conclusiones

El proyecto demuestra que los datos abiertos de SECOP II pueden organizarse en un flujo reproducible para medir señales de transparencia institucional. La mayor fortaleza es la trazabilidad entre datos crudos, limpieza, feature engineering, análisis, modelos y API. Además, el uso de variables tempranas hace que el caso de uso sea preventivo: priorizar procesos para revisión antes de depender de información posadjudicación.

La principal limitación es metodológica. Las métricas extremadamente altas y las advertencias de posible leakage indican que la etiqueta legacy puede ser parcialmente reconstruible a partir de variables relacionadas con su propia construcción. Por eso se recomienda validar con particiones temporales estrictas, revisar el target v2, ejecutar pruebas fuera de muestra y documentar una ficha de modelo con alcance, variables permitidas, umbral y restricciones de uso.

Como conclusión, SECOP Transparencia Temprana es un prototipo académico robusto para integrar Big Data, datos abiertos, ingeniería de variables, aprendizaje automático y operacionalización. Su valor está en mostrar cómo convertir información administrativa en alertas interpretables. Su uso responsable requiere mantener la distinción entre riesgo analítico y hallazgo de irregularidad, y complementar el modelo con revisión humana y contexto contractual.

9. Bibliografía

Colombia Compra Eficiente. (2024). SECOP II - Procesos de Contratación.
<https://www.colombiacompra.gov.co/archivos/conjunto-datos-abier/procesos-de-contratacion>

Colombia Compra Eficiente. (2025). Datos abiertos.
<https://www.colombiacompra.gov.co/datos-abiertos>

Decarolis, F., & Giorgiantonio, C. (2022). Corruption red flags in public procurement: new evidence from Italian calls for tenders. EPJ Data Science, 11, 16.
<https://doi.org/10.1140/epjds/s13688-022-00325-x>

Ferwerda, J., Deleanu, I., & Unger, B. (2017). Corruption in Public Procurement: Finding the Right Indicators. European Journal on Criminal Policy and Research, 23, 245-267.
<https://doi.org/10.1007/s10610-016-9312-3>

Naciones Unidas, Departamento de Asuntos Económicos y Sociales. (s. f.). Goal 16: Peace, justice and strong institutions. <https://sdgs.un.org/goals/goal16>

OECD. (2019). Reforming Public Procurement: Progress in Implementing the 2015 OECD Recommendation. OECD Publishing. https://www.oecd.org/en/publications/reforming-public-procurement_1de41738-en.html

Open Contracting Partnership. (s. f.). Open Contracting Data Standard.

<https://standard.open-contracting.org/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12(85), 2825-2830.

<https://www.jmlr.org/papers/v12/pedregosa11a.html>

10. Anexos

Anexo A. Código desarrollado

La Tabla 9 relaciona el código principal que puede revisarse o ejecutarse para sustentar el proyecto. Estos archivos se encuentran en el repositorio y permiten probar el flujo de punta a punta.

Tabla 9. Código principal del proyecto.

Ruta	Propósito
Code/DataPrep/descarga_datos_secop.py	Descarga de procesos SECOP II desde datos.gov.co/Socrata.
Code/Operationalization/crear_datos_analisis_secop.py	Construcción de la vista analítica sin campos posadjudicación.
Code/DataPrep/limpieza_datos_analisis_secop.py	Limpieza, normalización y control de duplicados.
Code/DataPrep/feature_engineering_secop.py	Creación de variables, scores y targets.
Code/Operationalization/analisis_descriptivo_secop.py	Análisis descriptivo y generación de salidas EDA.
Code/Operationalization/analisis_inferencial_secop.py	Pruebas inferenciales y asociaciones.
Code/Operationalization/pipeline_modelado_secop.py	Entrenamiento, validación y serialización de modelos.
Code/Operationalization/secop_fastapi/main.py	API FastAPI para predicción temprana.
Dockerfile y docker-compose.yml	Construcción y ejecución reproducible con contenedores.

Anexo B. Datos y artefactos evaluables

La Tabla 10 lista los datos y artefactos que soportan los resultados. Las rutas están incluidas para que el evaluador pueda inspeccionarlas directamente.

Tabla 10. Datos y artefactos de soporte.

Ruta	Contenido
Data/Raw/secop_procesos.parquet	Datos crudos descargados desde SECOP II.
Data/Raw/datos_analisis.parquet	Vista analítica inicial.
Data/Processed/Limpieza/datos_feature_engineering.parquet	Base enriquecida final para análisis y modelado.
Reports/FeatureEngineering/feature_engineering_summary.txt	Resumen de variables, scores y targets generados.
Reports/Model/metrics_summary_early.csv	Métricas de validación de modelos tempranos.
Reports/Model/best_model_report_early.txt	Reporte del mejor modelo early.
Models/trained/best_model_pipeline_early.joblib	Pipeline serializado del mejor modelo reportado.
Models/trained/all_models/RandomForest_early_pipeline.joblib	Pipeline usado por la API actual.
Docs/Project/Informe_Final_SECOP_Transparencia_Temprana.docx	Informe académico final en Word.

Anexo C. Ejecución sugerida

Para levantar la aplicación con Docker desde la raíz del proyecto:

```
docker compose up --build
```

Para consultar el estado del servicio:

```
curl http://127.0.0.1:8000/api/health
```

Para ejecutar localmente sin Docker, crear un entorno virtual, instalar requirements.txt y lanzar Uvicorn con Code.Operationalization.secop_fastapi.main:app. La documentación interactiva queda disponible en <http://127.0.0.1:8000/docs>.